E04 检索与回答依据

在 E03 实际输入中补上业务资料；连接 C 的过滤和 E02 的核对，不把引用当执行权限。

先找到获准且适用的资料，再生成并核对主张；相似或有引用都不能代替依据。

主图 · 先把关键关系接起来

知识归类

实线表示按本章关注点归组，不表示先后执行，也不是唯一分类。

让生成答案可追溯到原文

资料准备与适用范围

资料准备与版本（ingestion）
确认来源和使用范围，提取原文并建索引；新版导入还要处理旧片段退出，不能只追加。

切分资料并保留上下文（chunk / overlap）
以可理解的规则边界分块，必要时重叠保留条件；仅按字符切割可能拆掉动作前提。

资料属性筛选（metadata）
用角色、类别、日期和来源限制可取资料；授权过滤须发生在把内容交给模型以前。

生成与引用的支持关系

资料检索后生成（RAG）
检索后生成的方法
检索片段进入本次上下文后辅助生成；改变可见输入，不等于将资料训练进模型参数。

引用集合核对
检查非空引用确属本次取回片段；编号存在只证明可追踪，不证明回答受到内容支持。

主张与条件核对
判断原文是否支持回答并保留必要条件；窄短语检查不能证明任意自然语言都正确。

不可信输入与失败定位

间接提示注入
资料中夹带的命令仍是数据；模式拦截有限，须由应用限制资料、工具和执行权限。

无依据与分层诊断
资料不足时停止回答；沿原文、索引、过滤、输入和候选找最早缺口，再选择修复位置。

关键横向联系

同一知识点可以参与多种关系；箭头上的词才是连接含义。

切分资料并保留上下文（chunk / overlap） —保留所需条件→ **主张与条件核对**
若切块已丢掉前提，后续生成和引用编号都补不回原始依据。

引用集合核对 —不能替代→ **主张与条件核对**
真实引用仍可能被误解、反转条件或引用不可靠来源。

无依据与分层诊断 —检查最早缺口→ **资料检索后生成（RAG）**
修资料、过滤或输入的问题，不能统一用增加生成次数解决。

资料准备与版本（ingestion） —提供可检索资料→ **资料检索后生成（RAG）**
先登记资料版本与适用范围，再按当前任务取回材料；这不是把资料训练进模型。

同章续图：查找与表示。后页继续展开；分面不表示它们不属于本章。

E04 检索与回答依据

在 E03 实际输入中补上业务资料；连接 C 的过滤和 E02 的核对，不把引用当执行权限。

这里单独展开另一组关系，便于看清归属与交接；分面本身不表示选修或可以省略。

续图 · 与主图共同构成本章关系

知识归类

实线表示按本章关注点归组，不表示先后执行，也不是唯一分类。

让生成答案可追溯到原文

查找与表示

- **精确查询与语义检索**
  已知编号或业务字段优先确定性查找；表达不同而含义相近时，语义排序才可能有用。
- **向量表示与相似度（embedding）**
  数值表示与比较
  把问题和片段变成兼容向量再比较；向量不是原文或引用，换配置可能要求重建索引。
- **筛选候选结果（top-k / threshold）**
  限制返回数量并筛选相关性；最靠前不保证够用，过多片段也可能挤占上下文或引入冲突。

关键横向联系

同一知识点可以参与多种关系；箭头上的词才是连接含义。

资料属性筛选（metadata）（见主图） —限制候选范围→ **向量表示与相似度（embedding）**

相似度只在获准范围内比较，相关不等于有权读取。

精确查询与语义检索 —按任务选择查找方式→ **资料检索后生成（RAG，见主图）**

编号精确匹配与语义相近适合不同问题；并非凡是 RAG 都必须向量检索。

对照正文：E04 · 地图用于找关系，具体操作与例外仍回到本章。