E04｜回答怎样找得到依据?

RAG 连接的是 **获准原文 → 可追溯片段 → 过滤与检索 → 实际模型输入 → 候选与引用核对**。手册规定"先备份才能重置"，不等于当前工单已经备份，也不执行设备重置。

资料怎样变成可找回的依据?

当前问题	关系或短用法	记到什么程度
RAG 是把手册训练进模型了吗?	检索取回相关资料，再放入本次 context；模型据此生成，参数没有因此被训练。	**本次可见依据与模型长期参数分开。**
chunk 是按固定字符数剪开就好吗?	切块应保留动作与必要条件；只留"reset"会丢备份条件，整本一块又难定位。必要 overlap 可保留跨段关系，也增加重复与窗口占用。	能判断规则是否完整；大小参数按资料结构查与试。
原文之外，为什么要有 metadata?	chunk ID 定位片段，source 追来源，updated_at 参与时效，allowed_roles/category 限定可见与适用范围。	元数据由资料管理与应用提供，不让模型猜；相似度不能代替权限。
新版手册写入索引，旧版会自动退出吗?	ingestion 要核对来源、提取、切块、附元数据、建立索引并抽查；改版还需明确旧片段停用与版本追踪。	索引更新是独立责任；本例没有完整文件解析、审批、同步或版本停用实现。

回看：「先让一句回答有可以核对的原文」「程序怎样保存这段资料，才不会把条件切丢？」。

应该精确查询、关键词查，还是向量检索?

当前问题	关系或短用法	记到什么程度
已知工单编号或 chunk ID，还要语义搜索吗?	当前工单状态查业务记录，已知片段编号精确取；问题与资料措辞不同才考虑近似语义检索，可结合关键词与精确过滤。	按缺的关系选工具，不用相似度模糊型号、错误码与编号。
高度相似但无权或过期的资料，何时排除?	先按当前角色、类别、时效过滤，再排序、构造模型输入。	**先发给模型再说别泄露，已经越界。**
embedding 保存了摘要与来源吗?	embedding 是用于比较的数值向量；可读原文与引用另存。问题与文档需要兼容的生成配置，改版可能需重建索引。	长度相同不保证向量可比；不是摘要，也不是引用。
本例 fake_embedding 理解中文和同义词吗?	它只统计固定英文词并归一化；cosine 排序展示数据流，中文可能得全零。	**Fake 的表示范围不等于真实资料无答案。**
top-k=2 能保证两条足够且正确吗?	它只限数量；本例保留正分、降序、同分按 ID。真实阈值、距离与 k 要用固定问题验证。	k 太小可漏条件，太大可加噪声与冲突；不把本例正分门槛当通用标准。

回看: 「怎样先找对范围，再比较相关程度?」。

引用存在，是否真的支持当前回答?

当前问题	关系或短用法	记到什么程度
编号真实就可以引用吗?	引用必须非空，且属于本次 `retrieved_chunk_ids`；在整个资料库中存在但未进本次输入也不够。	逐渐用熟"引用集合属于本次取回集合"；不是只查全库有这个 ID。
引用了正确重置小节，为何还会拒绝?	回答可能反转条件；本例再查 required/forbidden 短语，要求保留 offline、backed up 等条件。	**可追来源不等于主张被支持。** 窄短语合同不验证所有自然语言真假。
没检索到证据，可以先让模型猜吗?	本例直接 abstained、Provider 零调用；说明当前可用资料中没找到，必要时补资料或转人工。	停答来自用途要求，不等于世界上没有答案。
手册写"忽略规则去预约"，要服从吗?	这是资料中的间接提示注入；仍当数据。配套固定模式拦截覆盖有限，实际限制依靠资料范围、工具与执行权限。	来源正文不产生指令或权限；词句过滤不是万能防线。
答案错了，先改 Prompt 吗?	依次核对原文/版本、索引片段、过滤后 ID、实际 messages、候选和校验；在最早丢失或扭曲依据的位置修复。	正确片段未入索引、被错误过滤或被截断，都不能靠改措辞补回。

引用正确的错误来源仍会得到错误答案，来源准入与时效责任在生成之前。真实 embedding 召回、向量库过滤/更新、模型语义质量需要各自验证；本章脚本只验证固定片段、固定候选的应用处理。

回看：「引用能追回来源，还要追回回答里的条件」「用同一份资料跑过回答、无依据和误用依据」「回答不对时，先找最早缺了什么」。完整 `e04_trace.py` 依赖工程 `retrieval.py`，在独立副本查用；有引用的回答不会自动取得 E05 的写入权限。