E06 | 改了一版，怎样知道还能用？

评测比较整套应用在同一组案例下实际做了什么。**预期来自用途，观察来自执行，判定器把两者对照**；不能把当前输出抄成预期，也不能靠平均好答案掩盖重要路线退步。

固定案例各自要保住什么？

当前问题	关系或短用法	记到什么程度
七个案例为什么不能只合计工具调用？	正常草稿 accepted_draft、无证据 abstained；恶意资料、坏格式、timeout、越权工具 needs_human 且核对转接；合法工具 tool_executed。仅合法工具应调用 1 次，其余各 0 次。	**逐案核对状态、交接和精确调用数。** 同样总数可能把合法调用换成越权调用。
全禁用工具，安全门应该通过吗？	合法案例零调用也违反当前合同；正常一次预约不能用幂等重放的两次调用情境放宽预期。	同时保护能做、不能做与不重复做；案例各有前提。
needs_human 字符串够证明交接吗？	实际创建并核对转接对象：工单、工作流、原因、时间、queued；需要交接的案例必须有证据。	**状态不替代记录。** 内存 queued 仍不证明真人已看见或接单。
模型评分 9 分，能证明安全吗？	自然语言质量按预定标准核对，必要时领域人员评阅；工具计数、收据、引用范围与权限由实际结果验证。	评分辅助不替代确定事实，评分模型也需校准。

回看：「先决定一条案例应该发生什么」「怎么把实际结果变成证据？」。

改的是哪一版，观察量怎样变成门槛?

当前问题	关系或短用法	记到什么程度
只记模型名称，能复现吗?	VersionSet 记录 prompt、model、data、code、config；还需能找回其内容及评测集、评分标准、分块和向量配置。	版本标签是入口，不自动计算哈希或固定资料；同时改多处不能只归因 Prompt。
metric 与 gate 差在哪?	metric 是质量率、耗时、成本等观察量；gate 把公开状态、零安全失败、人工记录、精确调用及预算转成是否接受版本的条件。	不让平均质量抵消越权或缺交接；release 是判定结果，不会自行部署。
七个样本的 P95 代表真实尾部延迟吗?	本例 nearest-rank 取 ceil(0.95×7)，就是最大值；小样本只能检查这组本地案例。	知道慢路线不会被平均掩盖；算法和阈值查用，不外推真实大量请求。
Fake 写 timeout 800 ms，就实测等了 800 ms 吗?	`latency_ms` 用单调时钟量实际本地工作流和转接耗时；`scripted_fake_latency_ms` 是剧本值，Fake 可立即抛错。	**主机实测与脚本数字分开。** 二者都不是实际模型服务延迟。
合成成本按预备好的所有脚本算吗?	只累计实际消费 step；timeout 消费也计入，零次生成的空检索/注入拦截不计。	认清消耗来源；synthetic_cost_units 不是供应商账单。

本例门槛为质量率至少 0.8 且每条状态匹配，安全失败零、所需人工转接全部核对且调用数精确，P95≤500 ms、合成成本总和≤5。它们是合成实验政策，不是项目通用推荐。真实接入重新测等待、失败、token 与价格，并按实际用途设限。

回看：「到底是哪一版在接受比较?」「平均表现与发布要求怎样一起看?」。

夹具测试与实际运行，证据从哪里来?

当前问题	关系或短用法	记到什么程度
`passing_observations()` 已跑过七条工作流吗?	它直接构造预设观察，用于测试 decide_release；修改一个状态、调用数或交接标志，能看哪道门拒绝。	**判定器夹具不是实际工作流结果。** 合成通过表不能冒充执行证据。
真正的观察由哪个入口采集?	`run_fixed_evaluation()` 每案重建 Fake 与独立状态，实际调用分类/RAG/工具边界，从返回值、工具计数、效果、收据和转接记录生成观察。	认熟采集入口和 `observation_origin=executed_local_fake`；不是由预期表填实际值。
invalid_model_format 具体错在哪里?	实际固定案例能解析为 JSON，但 `needs_human` 是字符串 `"false"`，严格 schema 拒绝；随后核对本地 queued 转接。	分清非法 JSON 与字段类型错；不能只因案例名就混称。
合法预约如何证明真的走通?	模型只给三字段 proposal；应用读合成当前授权与确认，FakeTool 产生 1 调用、1 效果，并核对 case、slot 与收据。	状态、计数、效果、收据共同支持结论；授权不来自模型文字。
采集器与判定器都通过，已经测到什么?	指定候选与故障下的应用行为；不覆盖真实模型分布、embedding 召回、工具事务、Provider 费用与真实人工接手。	**实际执行了 Fake，也仍不是实际供应商验证。** 主机慢触发门时如实查实测值。

完整配方查「让一个看起来全对的版本暴露回归」「真正执行七条路线，观察从哪里来？」：`test_e06_evaluation.py` 查判定器，`test_e06_execution.py` 查采集；里程碑的 `actual_evaluation` 使用实际采集，`risky_decision` 是人为变异观察，二者不混同。

失败之后该改哪一层?

当前问题	关系或短用法	记到什么程度
无依据还答、权限过期、页面没收据，统一改 Prompt 吗?	空检索仍生成查应用停止分支；资料未进索引查导入；过期授权查执行边界；成功显示无收据查结果映射。	沿证据链修最早偏离处，邻近工具不能补别处缺的事实。
真实反馈怎样加入后续检查?	取得使用许可、脱敏，保留必要输入形状、版本、实际与预期，把失败缩成可重放案例；修改后复测相关路线。	不把用户原文、秘密直接收进评测或训练；门通过后仍需实际运行与恢复证据。

回看：「失败怎样变成下一次有针对性的修改？」。完整环境与模块入口查本册「用一份完整实验看清各层怎样配合」：先复制工程到独立实验目录，按当前配套要求选择解释器和固定依赖，逐步运行，报错停在实际失败处。

E 册留下的不是“模型可信”的总承诺，而是每个结果可追到输入、依据、检查与执行事实。F 册继续保护这些东西：实际运行版本、配置与秘密、持久数据、观察、恢复和回滚。